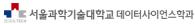
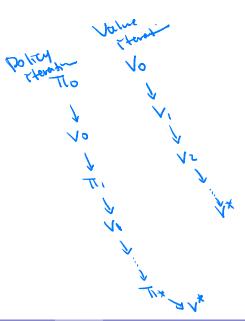
Lecture E3. MDP with Model 3

Sim, Min Kyu, Ph.D., mksim@seoultech.ac.kr



- I. Value improvement
- 2 II. Value iteration



I. Value improvement

Recap

- Major components of approaching MDP
 - (policy evaluation) We need to be able to evaluate $V^{\pi}(s)$ for a fixed π . This is called policy evaluation. This is also called as prediction in reinforcement learning.
 - (optimal value function) We want to be able to evaluate $V^{\pi^*}(s)$ where π^* is the optimal policy. The quantity, $V^{\pi^*}(s)$, is optimal policy's value function, or called shortly as optimal value function.
 - **(optimal policy)** We want to find the *optimal policy* π^* . This is also called as *control* in reinforcement learning
- This note aims to discuss **2. (optimal value function)** by iterative process.



Motivation

Policy improvement occurs by the following task of replacement. (E2, p9)

$$\pi^{new}(s) \leftarrow \underbrace{argmax_{a \in \mathcal{A}}}_{a \in \mathcal{A}} \left[R(s, a) + \gamma \sum_{\forall s'} \mathbf{P}^{a}_{ss'} V^{\pi^{old}}(s') \right], \text{ for all } s$$

Here lies the philosophy of dynamic programming:

If you find something better than the current scheme, it will be improved. Furthermore, it is guaranteed to reach the optimum by iteration.

 Value improvement (improvement in estimates for the optimal value function) occurs by the following task of replacement.

$$V_{new}(s) \leftarrow max_{a \in \mathcal{A}} \left\lceil R(s, a) + \gamma \sum_{\forall s'} \mathbf{P}^a_{ss'} V_{old}(s') \right\rceil, \text{ for all } s$$

• π is disappeared, why?

Strategy

- Review E2, p10 to develop strategy.
- $\bullet\,$ Algorithms are very similar between policy improvement and value improvement.

Preparation

```
gamma <- 1
states <- as.character(seq(0, 70, 10))
0.0.1.0.0.0.0.0.
                   0.0.0.1.0.0.0.0.
                   0,0,0,0,1,0,0,0,
                   0,0,0,0,0,1,0,0,
                   0,0,0,0,0,0,1,0,
                   0,0,0,0,0,0,0,1,
                   0.0.0,0,0,0,0,1),
  nrow = 8, ncol = 8, byrow = TRUE,
  dimnames = list(states, states))
P speed <- matrix(c(.1, 0,.9, 0, 0, 0, 0, 0,
                   .1, 0, 0, 9, 0, 0, 0, 0,
                   0,.1, 0, 0,.9, 0, 0, 0,
                   0, 0, .1, 0, 0, .9, 0, 0,
                   0. 0. 0. 1. 0. 0. 9. 0.
                   0, 0, 0, 0, 1, 0, 0, 9,
                   0, 0, 0, 0, 0, 1, 0, 9,
                   0, 0, 0, 0, 0, 0, 0, 1).
  nrow = 8, ncol = 8, byrow = TRUE,
  dimnames = list(states, states))
```

```
R_s_a <- matrix(
    c( -1, -1, -1, -1, 0.0, -1, -1, 0,
        -1.5,-1.5,-1.5,-0.5,-1.5,-1.5, 0),
    nrow = length(states), ncol = 2, byrow = FALSE,
    dimnames = list(states, c("normal", "speed")))</pre>
```

Implementation

```
# 1. Initialize V
                                                   # 3. Find the best action for each state
  V old <- array(rep(0,length(states)),</pre>
                                                  library(magrittr)
                dim=c(length(states),1))
                                                  V new <- apply(q s a, 1, max) %>%
  rownames(V old) <- states</pre>
                                                    as.matrix(dim = c(length(states,1)))
  t(V old)
                                                   t(V new)
         0 10 20 30 40 50 60 70
                                                           0 10 20 30 40 50 60 70
  ##
  ## [1,] 0 0 0 0 0 0 0 0
                                                  ## [1,] -1 -1 -1 -1 0 -1 -1 0
  # 2. Evaluate the Afunction
  qsa<-Rsa+
                                                     • This completes one-step value
    cbind(gamma*P normal**%V old,
                                                       improvement.
         gamma*P speed%*%V old)
       normal speed
                                            9 (s.a) = max R(s.a) + 8 PV(s)
  ## 0
           -1 -1.5
  ## 10
         -1 -1.5
                                              (-1+1.0 = -1 = b(30, n)
-1.5+(0.9 x 0 + 0.1 x 0) = -1.5
$ ## 20
         -1 -1.5
  ## 30
         -1 -1.5
          0 -0.5
  ## 40
  ## 50
           -1 -1.5
  ## 60
           -1 -1.5
```

9 9.9

70

Value , 17110710

II. Value iteration

$$\max_{n} g(s,n) = \max_{n} \begin{cases} -1+1 \times -1 & g(0,n) \\ -1.5 + (0.9 \times -1) & g(0.5) \end{cases}$$

Discussion

- Value iteration is to iterate value improvement until it converges.
- It is also greedy approach since looking at one-step improvement.
- Implementation is straight-forward given the prior implementation of value improvement.

Implementation

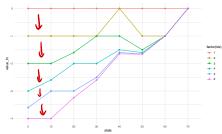
```
# Assigned are gamma, states, P_normal, P_speed, R_s_a
cnt <- 0
epsilon <- 10^(-8)
V_old <- array(rep(0,length(states)), dim=c(length(states),1))
rownames(V_old) <- states
results <- t(V_old) # to save
V
repeat{
    q_s_a <- R_s_a + cbind(gamma*P_normal%*%V_old, gamma*P_speed%*%V_old)
    V_new <- apply(q_s_a, 1, max) %>% as.matrix(dim = c(length(states,1)))
if (max(abs(V_new-V_old)) < epsilon) break
results <- rbind(results, t(V_new)) # to save
V_old <- V_new
cnt <- cnt + 1
}</pre>
```

```
value iter process <- results
results <- data.frame(results)
colnames(results) <- states</pre>
head(results)
##
                                                                           10
                                                                                                                20
                                                                                                                                                30
                                                                                                                                                                                   40
                                                                                                                                                                                                                          50 60 70
                                    0.0 0.0 0.00 0.0 0.00
                                                                                                                                                                                                          0.00
## 2 -1.0 -1.0 -1.00 -1.0 0.00 -1.00 -1
## 3 -2.0 -2.0 -1.60 -1.0 -1.00 -1.50 -1
## 4 -3.0 -2.6 -2.00 -2.0 -1.50 -1.60 -1
## 5 -3.6 -3.0 -3.00 -2.5 -1.60 -1.65 -1 0
## 6 -4.0 -4.0 -3.24 -2.6 -1.65 -1.66 -1 0
tail(results)
##
                                                                                       a
                                                                                                                                              10
                                                                                                                                                                                                             20
                                                                                                                                                                                                                                                                            30
                                                                                                                                                                                                                                                                                                                                        40
                                                                                                                                                                                                                                                                                                                                                                                                       50 60 70
## 17 -5.107742 -4.410773 -3.441077 -2.666666 -1.666667 -1.666667 -0.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.66667 -1.666667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.666
## 18 -5.107743 -4.410774 -3.441077 -2.666667 -1.666667 -1.666667 -1
## 19 -5.107744 -4.410774 -3.441077 -2.666667 -1.666667 -1.666667 -1
## 20 -5.107744 -4.410774 -3.441077 -2.666667 -1.666667 -1.666667 -1
## 21 -5.107744 -4.410774 -3.441077 -2.666667 -1.666667 -1.666667 -0.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.66667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.66667 -1.666667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1.6667 -1
```

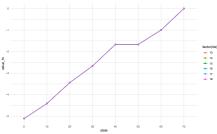
22 -5.107744 -4.410774 -3.441077 -2.666667 -1.666667 -1.666667 -0.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.666667 -1.66667 -1.66667 -1.666667 -1.66667 -1.666667 -1.66667 -1.666667 -1.66667 -1.666667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667 -1.66667

Visualization

• Iteration from 1 to 6.



• Iteration from 13 to 18.



• Iteration from 7 to 12.



• The previous plot was generated by the following code.

```
library(tidyverse)
results$idx <- as.numeric(row.names(results))
results <- results %>%
    gather(as.character(states), key="state", value="value_fn")
# the first figure
results %>% filter(idx <= 6) %>%
ggplot(aes(x=state, y=value_fn, group = factor(idx), color = factor(idx))) +
    geom_point() + geom_line() +
    theme_minimal()
```

Animated visualization

Animation Link

- The previous animation was generated by the following code.
- Check my L21 note in Data Visualization if interested.

```
library(gganimate)
library(gifski)
results$idx <- as.factor(results$idx)</pre>
fig static <-
  ggplot(results, aes(x=state, y=value fn, color=state)) +
  geom_point(size = 5) +
  theme_minimal()
fig dynamic <- fig static +
  transition states(idx) +
  labs(title = 'Now showing Iteration Number {closest state}') +
  enter_fade() + exit_shrink()
anim save(
  filename = "anim value iter.gif",
  animation = fig dynamic,
  renderer = gifski renderer())
```

Discussion

policy eval

- Why the process of **policy evaluation** is so similar to **value iteration**?
 - Policy evaluation is an iterative process to estimate the value function given a fixed policy.
 - Value iteration is an interative process to estimate the value function of the optimal policy.
 - Thus, the process is similar, both being based on the fixed point theorem.
- What is the difference between policy evaluation and value iteration?
 - Policy evaluation:

$$V_{new}^{\pi}(s) \leftarrow R^{\pi}(s) + \gamma \sum_{\forall s'} \mathbf{P}_{ss'}^{\pi} V_{old}^{\pi}(s'), \ \forall s \text{ (E1, p18)}$$

Value iteration:

$$V_{new}^*(s) \leftarrow \underbrace{\max_{a \in \mathcal{A}}} \left[R(s,a) + \gamma \sum_{\forall s'} \mathbf{P}_{ss'}^a V_{old}^*(s') \right], \ \forall s \text{ (this note, p5)}$$

 Value iteration (or, value improvement as its core component) includes taking maximum of Q-function among all available action.

Optimal value function \rightarrow Optimal policy

```
97(s.a) = R+ rP(V*)
```

```
V_opt <- t(tail(value_iter_process,1))
t(V_opt)</pre>
```

```
## 0 10 20 30 40 50 60 70
## [22,] -5.107744 -4.410774 -3.441077 -2.666667 -1.666667 -1.666667 -1
```

• Its corresponding optimal policy?

```
q_s_a <- R_s_a + cbind(gamma*P_normal%*%V_old,0 %
                     gamma*P speed %*%V old)
q s a
                                         094
         normal
                    speed
      -5.410774 -5.107744
## 10 -4 441077 -4 410774
  20 -3.666667 -3.441077
## 30 -2,666667 -3,344108
## 40 -1.666667 -1.666667
  50 -2.000000 -1.666667
## 60 -1.000000 -1.666667
## 70 0.000000 0.000000
pi opt vec <- apply(q s a, 1, which.max)
pi opt vec
```

 You may stop here, or transform pi_opt_vec into a matrix form as below.

```
pi_opt <- array(0,
    dim = c(length(states),2),
    dimnames = list(states, c("normal", "speed")))
for (i in 1:length(pi_opt_vec)) {
    pi_opt[i, pi_opt_vec[i]] <- 1
}
t(pi_opt)

##    0 10 20 30 40 50 60 70

## normal 0 0 0 1 1 0 1 1

## speed 1 1 1 0 0 1 0 0</pre>
```

10 20 30 40 50 60 70

"Success isn't permarnent, and failure isn't fatal. - Mike Ditka" ude no moder Shringto Cr: Ft deep end Crioter 219F